Préparé par
Dr R.BOUSMAHA

Fiche TP N° 01 : LE PRETRAITEMENT EN NLP

Objectif :

➔ Connaitre les notions de base des prétraitements en NLP

Librairies nécessaires

Nltk

SpaCy

WordCloud

Pywaffle

A. Préparation de données

LE PRETRAITEMENT EN NLP

1. Importer le jeu de données **spooky.csv** à partir de l'URL https://github.com/GU4243-ADS/spring2018-project1-ginnyqg/raw/master/data/spooky.csv en utilisant pandas et afficher les **10** premiers échantillons.

B. Nettoyage d'un texte

1. Gérer les caractères répétitifs (par exemple « cooooool » → « cool »)
2. Manipuler des homoglyphes (par exemple « $tupide » → « stupide »)
3. Transformer les entrées spéciales telles que les URL, les adresses e-mail et les balises HTML à une forme canonique.
4. Mettre tous les caractères en minuscule.
5. Supprimer la ponctuation
6. Supprimer les mots-vide.
7. Détecter les langues présentes dans le dataset et les traduire vers la langue la plus fréquente.
8. Après avoir traité les homoglyphes, supprimer les caractères spéciaux.
9. Supprimer les répétitions de mots (par exemple : "un un un...") et les espaces inutiles.

C. Segmentation

1. Segmenter chaque phrase sur les espaces / la ponctuation
2. Segmenter chaque phrase avec un algorithme de segmentation basé sur des règles
3. Segmenter chaque phrase avec un algorithme de segmentation en sous mots (Subword Tokenization)

D. Reconnaissance d'entité nommée

1. Pour chaque phrase représentait les entités nommées (avec NLTK ou SpaCy).
2. Pour chaque phrase, réaliser l'analyse des POS tags (part-of-speech).

E. Réduction des formes

1. Avec NLTK utiliser la lemmatisation et la racinisation.

Optionnel: Effectuer les mêmes tâches avec SpaCy

F. Analyse des fréquences

1. Compter le nombre de phrases, pour chaque auteur, où apparaît le mot **Great**.

2. Utiliser **pywaffle** pour obtenir un graphique qui résume de manière synthétique le nombre d'occurrences du mot " **great** " par auteur.

3. Refaire l'analyse avec le mot "impossible ".

4. En utilisant la fonction **wordCloud**, faire trois nuages de mots pour représenter les mots les plus utilisés par chaque auteur.

one
thing
time
seemed
old
now
saw
upon
though
house
even
came
found
man
place
must
night
men
day
never
dream
heard
window
backsee
little
light
long
street
beyond
strange
great
know
face
still
told
knew
door
two
life
last
many
yet
an
mind
eye
almost
much
whose
might
first
certain
made
world
thought
looked
away
around
death
horror
sound
ancient
something
town
side
book
stone
hand
home
toward
come
dead
half
left
right
way
half
black
year
dark
half
black
dear
half
black
half
black
half
black